

论文 3.1.2 节「LSTM：基于时间的趋势建模」解析

第一步：模型做了什么、原理与公式（含复现用的数据核查）

复现笔记 · 2025 MCM Problem C · Team #2500759

说明：本文是复现工作的第 1 步（读懂模型）。所有公式编号 (1)–(6) 与论文 3.1.2 节一致；文中标注「原文未明确」的部分，是复现时需要我们自己拍板的设计决策，将作为第 2 步写代码的输入。第 3 节的标准 LSTM 门控公式是论文没有写出、但复现必须实现的部分，已单独标注。

1 这个模块在论文中承担什么职责

论文的整体链条是：加权奖牌 → PCA 降维 → LSTM 趋势建模 → XGBoost-Bootstrap 区间预测 → 突破国家识别 / 小项归因 / DID 因果。3.1.2 节处在链条的中间，它既不直接输出最终奖牌预测，也不做任何统计检验，它只干一件事：

把每个国家“历届奥运会的金牌数与奖牌总数”这条带噪声、四年一采样、长度不等的序列，压缩成一个（或两个）能够代表其未来走向的“趋势值”（trend value），同时顺带把“东道主身份/备战效应”识别出来。这个趋势值随后作为 XGBoost 的输入特征，与 PCA 主成分、2028 年主场效应一起，被送进最终预测模型。

按论文 3.1.4 节的原文，XGBoost 的输入包括三项：各国 2028 年金牌与奖牌数的趋势值（本模块产出）；2024 年各大项奖牌权重的五个主成分维度（3.1.1 产出）；2028 年估计的主场效应值。所以本模块的交付物可以精确地写成：

$$\text{每个国家 } c \implies (\widehat{\text{Gold}}_{c,2028}^{\text{trend}}, \widehat{\text{Total}}_{c,2028}^{\text{trend}}) \quad (\text{并附带 } Host \text{ 识别结果})$$

2 模型具体做了什么（拆成 5 件事）

2.1 第 1 件事：把奖牌榜问题形式化为时间序列预测问题

论文开篇给出的建模动机有三条，值得逐条记住，因为它们决定了后面所有结构选择：

1. **奖牌数有时间连续性**：体育强国的奖牌数具有持续性（“国家实力”是一种慢变量），新兴国家则可能出现短期突破 $\implies$ 需要一个能刻画“长期水平 + 增/减趋势”的模型；
2. **四年一届导致常规时序模型失效**：样本点之间间隔 4 年、每国只有 20–30 个观测（见第 5 节数据核查），ARIMA 之类的等间隔假设与差分结构都不适用 $\implies$ 论文选择 LSTM，理由是“门控机制有助于保留关键历史信息”；
3. **数据含噪声且稀疏**：小国样本极少、奖牌数波动大 $\implies$ 论文明确写了“为应对数据稀疏问题，尤其是对数据点有限的小国，我们实现了一种正则化技术”（原文未指明是 dropout 还是 L_2 /早停，见 4.7 节待定项）。

2.2 第 2 件事：构造三类输入特征（式 (1)–(3)）

- 主场优势系数 α_c （国家层面、不随时间变化）：

$$\alpha_c = \frac{\text{Gold}_c^{\text{host}} - \text{Gold}_c^{\text{avg}}}{\text{Gold}_c^{\text{avg}}} \quad (1)$$

即“该国作为东道主时的平均金牌数”相对“其全部奥运会平均金牌数”的相对增益，作为该国的主场优势强度。原文未明确的是： $\text{Gold}_c^{\text{host}}$ 具体用哪几届、 $\text{Gold}_c^{\text{avg}}$ 是否只用同一时间窗、以及“经过归一化以作为权重”指的是何种归一化。

- 东道主指示变量 $\text{Host}_t \in \{0, 1\}$ ：该国在年份 t 是否为东道主（可由 `summerOly_hosts.csv` 直接得到，并需要做“国家名 $\rightarrow$ NOC 名”的映射）。
- 备战期效应 Prep_t ：

$$\text{Prep}_t = \begin{cases} 1, & t \in [t_{\text{host}} - 8, t_{\text{host}}] \\ 0, & \text{otherwise} \end{cases} \quad (2)$$

其中 t_{host} 是主办年份，8 年 = 两个奥运周期。含义是：申办成功后的两个周期内，该国投入上升，成绩被“预热”，因此在预测 2028 年（美国主办）时，美国在 2020、2024 两届的 Prep 应为 1。

- 输入向量：

$$\mathbf{x}_t = [\text{Gold}_t, \text{Total}_t, \text{Host}_t, \text{Prep}_t, \alpha_c] \quad (3)$$

即每个时间步 5 维：2 维“成绩”（金、总），2 维“身份/阶段”（是否主办、是否备战期），1 维“国家固有属性”（主场优势）。

2.3 第 3 件事：用“双通道 LSTM”分别吃两类特征（式 (4a)–(4c)）

$$\mathbf{h}_t^{\text{medal}} = \text{LSTM}_{\text{medal}}\left([\text{Gold}_{t-k}, \text{Total}_{t-k}]_{k=0}^{n_{\text{steps}}}\right) \quad (4a)$$

$$\mathbf{h}_t^{\text{host}} = \text{LSTM}_{\text{host}}\left([\text{Host}_{t-k}, \text{Prep}_{t-k}, \alpha_c]_{k=1}^{n_{\text{steps}}}\right) \quad (4b)$$

$$\hat{y}_t = \text{FC}(\mathbf{h}_t^{\text{medal}} \oplus \mathbf{h}_t^{\text{host}}) \quad (4c)$$

- $n_{\text{steps}} = 3$ ：使用最近三届奥运会的数据；
- $\oplus$ ：向量拼接（concatenation）；FC：全连接层； $\hat{y}_t$ ：预测值；
- 通道分工：*medal* 通道学“成绩自身的惯性/趋势”（输入 2 维 $\times$ 时间步）；*host* 通道学“主场与备战如何调制成绩”（输入 3 维 $\times$ 时间步）。最后把两个隐状态拼起来做回归。
- 原文的一处不一致：(4a) 的下标是 $k = 0, \dots, n_{\text{steps}}$ （4 个时间步），(4b) 是 $k = 1, \dots, n_{\text{steps}}$ （3 个时间步）。复现时建议统一为“最近三届” $k = 1, 2, 3$ 并记录该差异（见 4.6 节）。

2.4 第 4 件事：用“分层损失”把回归任务和东道主识别任务绑在一起训练（式 (5a)–(5c)）

$$\mathcal{L} = \lambda_1 \mathcal{L}_{\text{medal}} + \lambda_2 \mathcal{L}_{\text{host}} \quad (5a)$$

$$\mathcal{L}_{\text{medal}} = \frac{1}{N} \sum_{t=1}^N \left[(y_t^{\text{Gold}} - \hat{y}_t^{\text{Gold}})^2 + (y_t^{\text{Total}} - \hat{y}_t^{\text{Total}})^2 \right] \quad (5b)$$

$$\mathcal{L}_{\text{host}} = -\frac{1}{N} \sum_{t=1}^N \left[\text{Host}_t \log(\hat{p}_t) + (1 - \text{Host}_t) \log(1 - \hat{p}_t) \right] \quad (5c)$$

其中 $\lambda_1 = 0.7$ 、 $\lambda_2 = 0.3$ 、 $\hat{p}_t = 0.1$ 。

- $\mathcal{L}_{\text{medal}}$ ：对金牌与奖牌总数同时做均方误差（注意不是加权，两项等权相加），一个网络同时输出两个目标；
- $\mathcal{L}_{\text{host}}$ ：以 Host_t 为标签的二元交叉熵（BCE）， $\hat{p}_t$ 是模型对“年份 t 是主办年”的预测概率。这个分支本质是一个辅助分类任务：它迫使 host 通道的隐状态必须编码“是否主办/是否备战”的信息，从而在多任务意义上起到正则化作用，也解释了论文为什么说 LSTM “可以引入东道主国家指标之类的额外特征”；
- 原文疑点：式 (5c) 下面把 $\hat{p}_i$ 写成了常数 0.1。若真取常数，BCE 就没有梯度、分类头失去意义。复现时按“网络输出的概率”实现：host 通道隐状态 $\rightarrow$ 线性层 $\rightarrow$ sigmoid $\rightarrow \hat{p}_i$ ，并把 0.1 作为初始化先验或标签平滑系数做消融。完整考证见 4.2 节。

2.5 第 5 件事：用 WMAE 调参，确定结构规模（式 (6)）

$$\text{WMAE}_{\text{Gold or Total}} = \frac{\sum_c w_c |y_c - \hat{y}_c|}{\sum_c w_c} \quad (6)$$

w_c 是国家 c 的金牌数（或奖牌总数）权重， y_c 为真实值、 $\hat{y}_c$ 为预测值。即“按国家奖牌规模加权的平均绝对误差”——预测美国误差 3 枚与预测小国误差 3 枚的代价不同，用 WMAE 更贴合“奖牌榜”的语义。

调参过程（论文图 3、图 4）：

- 网格：hidden_size $\times$ patience，候选含 32×6 、 64×8 、 64×10 、 128×10 等；
- WMAE_Gold 与 WMAE_Total 两条曲线分别看；
- 结论： 32×6 最优（局部）， 64×8 与 64×10 达标， 128×10 最好；三种直接比较后 128×10 总体误差最低：

hidden_size = 128,	patience = 10
--------------------	---------------

- 该配置随后“为涉及 XGBoost 的研究提供了关键的趋势度量”。

3 原理：LSTM 为什么适合这个任务（含标准门控公式）

3.1 论文给出的理由（原文逻辑）

- 需要长程依赖：“若某国最近三届持续增长，LSTM 能识别该趋势并外推”；
- 需要抗噪：“奖牌数据可能含噪、部分国家表现不稳，LSTM 通过学习更宏观的趋势来缓解”；

- 需要处理 4 年间隔：门控结构（而非简单的 RNN）能通过单元状态 c_t 保留跨届信息，从而提升精度。

3.2 标准 LSTM 单元（论文未列出、复现必须实现）

对每个时间步 t ，设输入 $\mathbf{x}_t$ 、上一时刻隐状态 $\mathbf{h}_{t-1}$ 、单元状态 $\mathbf{c}_{t-1}$ ：

$$\mathbf{f}_t = \sigma(\mathbf{W}_f[\mathbf{h}_{t-1}; \mathbf{x}_t] + \mathbf{b}_f) \quad \text{遗忘门：丢掉多少历史} \quad (1)$$

$$\mathbf{i}_t = \sigma(\mathbf{W}_i[\mathbf{h}_{t-1}; \mathbf{x}_t] + \mathbf{b}_i) \quad \text{输入门：写入多少新信息} \quad (2)$$

$$\tilde{\mathbf{c}}_t = \tanh(\mathbf{W}_c[\mathbf{h}_{t-1}; \mathbf{x}_t] + \mathbf{b}_c) \quad \text{候选状态} \quad (3)$$

$$\mathbf{c}_t = \mathbf{f}_t \odot \mathbf{c}_{t-1} + \mathbf{i}_t \odot \tilde{\mathbf{c}}_t \quad \text{单元状态更新（跨届记忆的载体）} \quad (4)$$

$$\mathbf{o}_t = \sigma(\mathbf{W}_o[\mathbf{h}_{t-1}; \mathbf{x}_t] + \mathbf{b}_o) \quad \text{输出门} \quad (5)$$

$$\mathbf{h}_t = \mathbf{o}_t \odot \tanh(\mathbf{c}_t) \quad \text{隐状态输出} \quad (6)$$

其中 σ 为 sigmoid、 $\odot$ 为逐元素乘。对本问题的意义： $\mathbf{c}_t$ 提供了“几乎无衰减”的记忆通道，因此“过去三届是否持续增长”这类信息可以被携带到当前步；同时遗忘门可以主动丢弃“冷战时期苏联/民主德国”这类已经不存在国家口径的历史噪声（这也是国家口径断裂问题的技术缓解手段）。

3.3 与本问题匹配的结构选择

表 1：论文的结构选择及其动机

结构选择	具体做法	动机（对应的问题）
双通道	medal 通道（金、总）+ host 通道（主办、备战、 α_c ）	两类变量尺度与语义不同，避免互相干扰
多任务损失	回归（MSE）+ 主办识别（BCE），权重 0.7/0.3	迫使表征保留主场信息；小样本下的正则化
权重重采样指标	WMAE（按国家奖牌规模加权）	与“奖牌榜”的现实代价一致，避免小国主导误差
早停	patience（最大可容忍不提升的轮数）	小样本防过拟合；同时作为调参维度
序列长度	$n_{\text{steps}} = 3$ （最近三届）	兼顾“趋势可辨识”与“不引入过时信息”

4 公式逐条落地：符号、数据来源与实现方式

4.1 训练样本怎么切（滑动窗口）

以美国为例（真实数据，取自 `summerOly_medal_counts.csv`）：

表 2：式 (1)–(6) 的复现落地表

公式	符号	数据来源 / 计算方式	复现注意点
(1)	α_c 主场优势系数	summerOly_medal_counts.csv 中该国的 Gold; summerOly_hosts.csv 判定主办届	是否把 2024 (法国主场) 与 2028 (美国主场) 计入均值会造成信息泄漏; 建议只用“预测目标届之前的历史主办届”
(2)	$Prep_t$ 备战期	主办年份 t_{host} ; 窗口 $[t_{\text{host}} - 8, t_{\text{host}}]$	2028 年美国主办 $\Rightarrow$ 美国 2020、2024 的 $Prep = 1$; 注意 2020 实际在 2021 举办, 仍按“届次”计
(3)	$\mathbf{x}_t$ 输入向量	同上一行 + 该国该届 Gold、Total	需先把 NOC 名称清洗 (见 5.2 节) 并把“未参赛届”补 0 或做掩码
(4a)	$\mathbf{h}_t^{\text{medal}}$	窗口 $[\text{Gold}_{t-k}, \text{Total}_{t-k}]$	下标 $k = 0..3$ (4 步) 与“最近三届”矛盾, 建议统一为 3 步
(4b)	$\mathbf{h}_t^{\text{host}}$	窗口 $[\text{Host}_{t-k}, \text{Prep}_{t-k}, \alpha_c]$	原文下标 $k = 1..3$; α_c 是常量特征, 可在每步重复拼接
(4c)	$\hat{y}_t$	两个隐状态拼接 $\rightarrow$ 全连接层	输出维度 2 (Gold、Total); 建议再加一个 sigmoid 头输出 $\hat{p}_t$
(5b)	$\mathcal{L}_{\text{medal}}$	对 Gold 与 Total 的 MSE 求和	两目标量纲相同, 直接等权; 若做标准化需注意反变换
(5c)	$\mathcal{L}_{\text{host}}$	以 Host_t 为标签的 BCE	$\hat{p}_t$ 应为网络输出; 原文 $\hat{p}_t = 0.1$ 疑为笔误
(6)	WMAE	w_c 取该国金牌数/奖牌总数	需明确 w_c 是“真实值”还是“历史平均”, 论文未说明

届次	2012	2016	2020	2024	...
Gold	48	46	39	40	
Total	104	121	113	126	

若按“窗口 = 最近三届 → 预测下一届”的无泄漏切法，可得到训练样本：

样本	输入窗口 $(t-2, t-1, t)$	目标届	标签
#1	2008(36/112), 2012(48/104), 2016(46/121)	2020	(39, 113)
#2	2012(48/104), 2016(46/121), 2020(39/113)	2024	(40, 126)
#3	2016(46/121), 2020(39/113), 2024(40/126)	2028	待预测（趋势值）

重要说明：论文式 (4c)、(5b) 把 $\hat{y}_t$ 与 y_t 直接对齐（同一 t ），而 $\mathbf{x}_t$ 内又含 Gold_t ，这在实现上会构成同期信息泄漏（用当年成绩预测当年成绩）。结合论文 3.1.4 节“利用 2024 年数据推导 2028 年预测”的表述，其真实意图显然是“用截至 t 的窗口预测 $t+1$ ”，因此复现时采用上表的错位切法，并把该处作为“与原文写法的差异”记录。

4.2 专门考证：原文的 $\hat{p}_i = 0.1$ 到底是什么

(1) 原文有没有给理由？——没有。全文（含图像页第 7 页的高倍放大核对）关于 $\hat{p}$ 只有一处：式 (5c) 下方的“where $\lambda_1 = 0.7, \lambda_2 = 0.3, \hat{p}_i = 0.1$ 。”摘要、3.1.2 正文、图 1 流程图、第 6–7 章均未再提及，也没有任何“为什么取 0.1”的说明。公开检索也未找到该队（Team #2500759）的代码仓库可供验证，因此只能从文本与数学上推断。注意下标是 i （样本级）而不是 t ：逐样本的预测概率不可能是一个全局常数，这本身就说明该行写法自相矛盾。

(2) 若真取常数，这一项在训练中是“死”的。把 $\hat{p}_i \equiv 0.1$ 代入 (5c)，设 $H = \sum_i \text{Host}_i$ ：

$$\begin{aligned}\mathcal{L}_{\text{host}} &= -\frac{1}{N} \left[H \log 0.1 + (N - H) \log 0.9 \right] \\ &= -\frac{1}{N} \left[(\log 0.1 - \log 0.9) H + N \log 0.9 \right] = \underbrace{2.197}_{-\log(1/9)} \cdot \frac{H}{N} - \log 0.9.\end{aligned}$$

右边两项都与网络参数无关， H/N 由数据决定，因此 $\partial \mathcal{L}_{\text{host}} / \partial \theta \equiv 0$ ：它只是给总损失加了一个常数， $\lambda_2 = 0.3$ 也随之失去意义。结论：这一行几乎可以确定是笔误或符号混用，而不是一个有意设计。

(3) 作者“本来想写”的最可能是哪一个？（按可能性排序）

(4) 为什么这个数字会出现在这里：类别极度不平衡。用实际数据统计 host 标签的基率（把 summerOly_hosts.csv 的国家名映射到 medal_counts 的 NOC）：

样本口径	样本数	主办样本数	基率
全部 1435 行（1896–2024）	1435	30	2.09%
1952 年后	1174	19	1.62%
出现 ≥ 5 届的 87 国子面板	1289	30	2.33%

表 5: $\hat{p}_i = 0.1$ 的四种候选解释

序	解释	支持理由	复现后果
A	$\hat{p}_i$ 是网络输出, 0.1 是分类头偏置初始化 / 先验基率	小样本 + 极端不平衡 (见下) 时的标准技巧: $b = \log \frac{0.1}{0.9} \approx -2.197$, 让训练初期就输出 ≈ 0.1 , 避免被多数类 (非主办) 主导	主线实现; 并把 0.1 作为初始化解做消融
B	0.1 是标签平滑系数 ε (正类目标 0.9、负类 0.1)	BCE 软标签写法中, 参数列表里出现 0.1 非常自然; 作者把 ε 与 $\hat{p}$ 混写	作为消融项 B 实现
C	0.1 是正类先验权重 (用于反频率加权/先验正则)	动机同样是类别不平衡	更标准的做法是 $\text{pos_weight} \approx N_-/N_+ \approx 48$; 作对照
D	抄错常数 (把别处的常数写进 where 行)	3.2 节的判定阈值是“位置参数 $\theta = 1$ ”, 与 0.1 无关	直接忽略

基率只有 2% 左右, 而 0.1 是它的约 5 倍, 因此 0.1 不是“精确的基率”。这反而支持解释 A/B: 作者需要的不是精确基率, 而是“一个量级合适的小先验”, 用来防止辅助任务在极端不平衡下塌缩成“永远预测非主办”。**动机合理、写法错误**, 这是最符合上下文的判断。

(5) 复现方案 (第 2 步执行)。

- 主线: $\hat{p}_i = \sigma(\mathbf{w}^\top \mathbf{h}_i^{\text{host}} + b)$, 用标准 BCE ((5c)) 训练, $\lambda_2 = 0.3$;
- 消融 A: b 初始化为 $\log(0.1/0.9) \approx -2.197$;
- 消融 B: 标签平滑 $\varepsilon = 0.1$ (正类目标 0.9、负类目标 0.1);
- 对照 C: $\text{pos_weight} \approx 48$ 的反频率加权;
- 评价: 除 WMAE 外, 额外报告 host 分类头的 AUC/F1, 并对比三者 in WMAE 上的差异, 写入复现报告的“原文未明确参数的敏感性分析”一节。

4.3 序列特征工程 (复现时需自己决定)

- 国家筛选: 全部 210 个名称中出现 ≥ 10 届的只有 53 个国家; 若想覆盖“首次夺牌国家”(如 SMR、KWT), 需要设定较低门槛 (例如 ≥ 3 届, 共 112 国) 或对稀疏国家做零填充 + 掩码;
- 缺失届次: 某国未参赛/未获奖的年份, `medal_counts` 中没有该行, 需显式补 0 (比赛参加但无奖牌) 与“未参赛”区分开;
- 时间范围: 建议只用现代奥运会 (如 1952 年或 1992 年后), 因为苏联、民主德国、南斯拉夫等国家口径已断裂;
- 归一化: Gold/Total 量纲跨度过大 (0–231), 需标准化或对数变换; Host 、 Prep 保持 0/1; α_c 做 min-max 或 z-score;
- 正则化: 论文只说“实现了正则化技术”, 复现时建议 dropout + 早停 + 权重衰减三选一并记录。

5 数据侧核查（基于已下载的 5 个数据文件）

5.1 文件与用途

表 3: 5 个数据文件与 3.1.2 节的对应关系

文件	规模	在 3.1.2 节中的用途 / 关键字段
summerOly_medal_counts.csv	1435 行	主表。字段 Rank, NOC, Gold, Silver, Bronze, Total, Year; 提供每国每届的金牌/总数序列
summerOly_hosts.csv	35 行	字段 Year, Host (形如 “Los Angeles, United States”) $\Rightarrow$ 生成 $Host_t$ 、 $Prep_t$, 并定位 2028 主办国
summerOly_programs.csv	74 行	字 段 Sport, Discipline, Code, Sports Governing Body + 32 个年份列 (小项数量)。本模块不直接用, 但 3.1.1 的 PCA 需要它
summerOly_athletes.csv	23.8 MB	运动员级明细 (Name, Sex, Team, NOC, Year, City, Sport, Event, Medal)。本模块不直接用, 可用于校验或构造更细的特征
data_dictionary.csv	—	字段说明与示例

5.2 实际数据里已经发现的坑（复现前必须处理）

1. NOC 名称有大量尾部空格: 如 "Argentina ", "Great Britain ", 务必 strip(); 否则会被统计成两个国家 (去重后 “210 个 NOC” 中有一部分是这类伪重复);
2. 东道主名称与 NOC 名称不一致: hosts 文件写 “London, United Kingdom” “Munich, West Germany” “Moscow, Soviet Union”, 而奖牌表里是 Great Britain、West Germany、Soviet Union。“United Kingdom” 在奖牌表中不存在, 必须映射为 “Great Britain”;
3. 共 30 届 (1896–2024), 不含 1906 年间届奥运会, 也不含 1916/1940/1944 三届停办; hosts 文件里这三届以 “Cancelled (...)” 形式存在, 需要过滤;
4. coverage 极不平衡: 出现 ≥ 20 届的国家仅 22 个, ≥ 10 届 53 个, ≥ 5 届 87 个, 全部 210 个名称中大部分只有 1–2 届记录;
5. 2024 年只有 91 个国家上榜 (有奖牌), 而 “首次夺牌” 任务恰恰关心没有奖牌的国家——这类国家在奖牌表中 “缺席” 而非 “为 0”。

5.3 用真实数据演练一次 α_c (式 (1))

以美国为例（主办届 1904、1932、1984、1996；不把未来的 2028 计入）：

国家	主办届平均金牌	全部届平均金牌	α_c
美国 United States	61.75 (1904/1932/1984/1996)	38.10 (29 届)	0.6206
法国 France	18.67 (1900/1924/2024)	8.00 (30 届)	1.3333

可以看到两点：(i) 该定义能给出量级合理的“主场增益”（美国 +62%、法国 +133%）；(ii) 法国的 α_c 把 2024 年（正是要解释的“主场爆发”届）计入了主办平均，这会造成信息泄漏——复现时必须明确“计算 α_c 时排除目标届”，否则 2028 年的美国预测会被 2028 主场信息污染。

6 交付物与下游接口

本模块训练完成后应产出：

- **趋势值表**（核心交付物）：Country, Gold_trend_2028, Total_trend_2028——即“截至 2024 的窗口”前向一次的输出；
- **主办识别输出**： $\hat{p}_t$ （尤其对 2028 年美国、2024 年法国的 $\hat{p}$ 值），可用于论文中“主场效应”的论述；
- **训练诊断**：WMAE 随 hidden_size/patience 的变化曲线（对应论文图 3、图 4）、训练/验证损失曲线；
- **与下游 XGBoost 的接口约定**：趋势值必须与 XGBoost 的样本表按 (Country, Year) 对齐；由于 XGBoost 用的是“2028 趋势值”，本模块对训练期国家输出的是“每一步的历史趋势值”还是“只输出 2028”，需要在第 2 步实现时明确（论文未说明）。

7 复现待定清单（论文未明确，第 2 步需拍板）

8 小结（一句话版）

3.1.2 节做的事：把每国“金牌/奖牌总数”的历史序列，连同“是否东道主/是否处于 8 年备战窗口/该国主场优势系数”一起，喂给一个**双通道 LSTM**；medal 通道学成绩趋势，host 通道学主场与备战效应，两者拼接到全连接层输出下一届的“趋势值”；训练时用**加权 MSE (0.7) + 主办识别 BCE (0.3)** 的联合损失，用 **WMAE** 调参，最终确定 hidden_size = 128、patience = 10；产出的趋势值交给 XGBoost 做最终的区间预测。

下一步(第 2 步)要做的事：读入 5 个数据表 → 清洗 NOC/东道主名称 → 构造 $Host/Prep/\alpha_c$ → 按 $t \rightarrow t+1$ 切滑动窗口 → 实现双通道 LSTM 与联合损失 → 网格搜索 hidden_size/patience → 输出 2028 年趋势值 → 画出图 3/图 4 同款调参图。

表 4: 复现参数与设计决策清单

编号	事项	论文的写法	复现建议
1	国家纳入门槛	未说明	主实验用 ≥ 5 届（87 国），稳健性对比 $\geq 3/\geq 10$ 届
2	时间起点	未说明	1952 年后为主；1992 年后作对比（口径稳定性）
3	序列长度	$n_{\text{steps}} = 3$ （表述不一致）	统一取 3，并做 2/4 的灵敏度分析
4	预测对齐	式 (4c)、(5b) 同 t 对齐	改为 $t \rightarrow t + 1$ 错位，避免信息泄漏
5	α_c 的算法	“回归估计 + 归一化”	按式 (1) 直接算，且 排除目标届 ；再试“回归残差”版本作对比
6	$\hat{p}_t$ 的实现	写作常数 0.1（疑误）	用 sigmoid 分类头输出概率，BCE 训练
7	正则化方式	只说“实现了正则化技术”	dropout(0.2) + 早停 (patience) + weight_decay，逐项消融
8	网络细节	未给出层数、优化器、学习率、batch、epoch	单层双向/单向 LSTM 各试一次；Adam(lr= 10^{-3})、batch = 16、最多 200 epoch、早停 patience = 10
9	损失权重	$\lambda_1 = 0.7, \lambda_2 = 0.3$	直接采用；做 0.5/0.5、0.9/0.1 的对比
10	随机性	未说明随机种子	固定种子，重复 5 次报告均值 $\pm$ 标准差
11	WMAE 的 w_c	只说“国家 c 的金牌数或奖牌总数的权重”	分别用“真实当届金牌数”与“历史平均金牌数”两版对比
12	输出趋势值的口径	未说明	明确为“模型对下一届的预测值”，并在文档中固定